

基于深度残差卷积神经网络的心电信号心律不齐识别



李端^{1,2}, 张洪欣^{1,3}, 刘知青⁴, 黄菊香¹, 王田⁵

1. 北京邮电大学 电子工程学院 (北京 100876)
2. 郑州轻工业大学 计算机与通信工程学院 (郑州 450002)
3. 北京市安全生产智能监控重点实验室 (北京 100876)
4. 智慧康源(厦门)科技有限公司 (福建厦门 361010)
5. 北京航空航天大学 自动化科学与电气工程学院 (北京 100191)

【摘要】 心电图(ECG)信号在采集过程中容易受内部和外部噪声干扰,而且不同患者的ECG信号形态特征差异较大,即使同一患者在不同时间和环境下其ECG信号也会有差异,因此ECG信号特征检测与识别在心脏病远程实时监测与智能诊断中具有一定难度。基于此,本研究提出将小波自适应阈值去噪和深度残差卷积神经网络算法用于多种心律不齐的信号识别过程中。其中,使用小波自适应阈值技术完成ECG信号滤波,并设计了包含多个残差块(residual block)结构的20层卷积神经网络(CNN),即深度残差卷积神经网络(DR-CNN),对5大类心律不齐ECG信号进行了识别。然后,本文采用残差块局部神经网络结构单元构建DR-CNN,缓解了深层网络的收敛难、调优难等问题,克服了CNN随着网络层数增加而导致的退化问题;进一步引入批标准化(batch normalization)技术,保证了网络的平滑收敛。按照美国医疗器械促进协会(AAMI)的心搏分类标准,使用麻省理工学院和波士顿贝丝以色列医院(MIT-BIH)心律不齐数据库中94 091个ECG心搏信号(2个导联),完成了心律不齐多分类、室性异位搏动(Veb)和室上性异位搏动(Sveb)等分类识别实验。实验结果表明,本文所提出的方法在ECG信号多分类、Veb和Sveb识别中的准确率分别达到了99.034 9%、99.498 0%和99.334 7%。在相同的数据集和实验平台下,DR-CNN在分类准确率、特异性和灵敏度上均优于相同结构复杂度的CNN、深度多层感知机等传统算法。DR-CNN算法提高了心律不齐智能诊断的精度,该方法与可穿戴设备、物联网和无线通信技术相结合,可以将心脏病的预防、监测和诊断延伸到家庭、养老院等院外场景,从而提高心脏病患者的救治率,并且有效地节约医疗资源。

【关键词】 心电图;小波自适应滤波;深度残差卷积神经网络;心律不齐分类;美国医疗器械促进协会

Deep residual convolutional neural network for recognition of electrocardiogram signal arrhythmias

LI Duan^{1,2}, ZHANG Hongxin^{1,3}, LIU Zhiqing⁴, HUANG Juxiang¹, WANG Tian⁵

1. School of Electronic Engineering, Beijing University of Posts and Telecommunications, Beijing 100876, P.R.China
 2. School of computer and communication Engineering, Zhengzhou University of Light Industry, Zhengzhou 450002, P.R.China
 3. Beijing Key Laboratory of Work Safety Intelligent Monitoring, Beijing 100876, P.R.China
 4. Wisdom healthy technology co., Ltd, Xiamen, Fujian 361010, P.R.China
 5. School of Automation Science and Electrical Engineering, Beihang University, Beijing 100191, P.R.China
- Corresponding author: ZHANG Hongxin, Email: hongxinzhang@263.net

【Abstract】 Electrocardiogram (ECG) signals are easily disturbed by internal and external noise, and its morphological characteristics show significant variations for different patients. Even for the same patient, its characteristics are variable under different temporal and physical conditions. Therefore, ECG signal detection and recognition for the heart disease real-time monitoring and diagnosis are still difficult. Based on this, a wavelet self-adaptive threshold denoising combined with deep residual convolutional neural network algorithm was proposed for multiclass

DOI: 10.7507/1001-5515.201712031

基金项目: 国家自然科学基金(61571063, 61503017); 北京市自然科学基金(3182028); 航空科学基金(2016ZC51022); 厦门湖里区项目(17社05)

通信作者: 张洪欣, Email: hongxinzhang@263.net

arrhythmias recognition. ECG signal filtering was implemented using wavelet adaptive threshold technology. A 20-layer convolutional neural network (CNN) containing multiple residual blocks, namely deep residual convolutional neural network (DR-CNN), was designed for recognition of five types of arrhythmia signals. The DR-CNN constructed by residual block local neural network units alleviated the difficulty of deep network convergence, the difficulty in tuning and so on. It also overcame the degradation problem of the traditional CNN when the network depth was increasing. Furthermore, the batch normalization of each convolution layer improved its convergence. Following the recommendations of the Association for the Advancements of Medical Instrumentation (AAMI), experimental results based on 94 091 2-lead heart beats from the MIT-BIH arrhythmia benchmark database demonstrated that our proposed method achieved the average detection accuracy of 99.034 9%, 99.498 0% and 99.334 7% for multiclass classification, ventricular ectopic beat (Veb) and supra-Veb (Sveb) recognition, respectively. Using the same platform and database, experimental results showed that under the comparable network complexity, our proposed method significantly improved the recognition accuracy, sensitivity and specificity compared to the traditional deep learning networks, such as deep Multilayer Perceptron (MLP), CNN, etc. The DR-CNN algorithm improves the accuracy of the arrhythmia intelligent diagnosis. If it is combined with wearable equipment, internet of things and wireless communication technology, the prevention, monitoring and diagnosis of heart disease can be extended to out-of-hospital scenarios, such as families and nursing homes. Therefore, it will improve the cure rate, and effectively save the medical resources.

【Key words】 electrocardiogram; wavelet adaptive filtering; deep residual convolutional neural network; arrhythmia classification; the Association for the Advancement of Medical Instrumentation

引言

心电图 (electrocardiogram, ECG) 是记录心脏每一心动周期电活动的可视化时间序列, 它的形态特征可反映潜在的心律不齐症状^[1-2]。由于心脏病的突发性和难以预测性, 建立有效的、延伸到医院以外的远程实时监护体系, 对患者进行实时 ECG 信号监测并及时发现心脏异常变化对心血管病预防和救治具有重要意义^[3-4]。

ECG 信号在采集过程中容易受工频噪声、肌电噪声、基线漂移和运动伪影等干扰, 而且患者间个体差异大, 同一患者在不同时间的测试结果也会受当时身体状况的影响, 即使有经验的专家也很难完全准确地判断疾病类型。随着人工智能技术的发展, 很多模式识别的方法已被用于 ECG 信号的分类识别, 比如: 小波分析、功率谱估计、主成分分析结合神经网络、随机森林、聚类和支持向量机等智能识别算法^[5-10]。尽管传统的模式识别方法已取得了一定的研究成果, 但是目前临床 ECG 信号采集设备大多是按照传统的特征提取方法提取心率、ST 段特征等信息, 再经过简单分析给出粗略建议, 并没有实现多种心律不齐的智能诊断。总的来说, 目前的 ECG 数据自动诊断方法存在如下问题: ① 如果前期特征提取效果不好, 将导致最终的分类准确率下降; ② 浅层神经网络分类器针对大数据训练效率不高, 非线性拟合能力差, 准确率有限; ③ 很多方法对小样本测试效果良好, 面向

临床大数据诊断则效果下降, 仍无法用于临床辅助诊断。

近几年, 深度学习算法不仅在图像识别、语音识别等领域取得了瞩目的成就, 也广泛用于基于 ECG 信号的心脏病辅助诊断^[11-14]。相比传统的浅层神经网络而言, 深度神经网络具有更强的非线性拟合能力^[15], 在单导联、部分数据集、少类别 ECG 心搏信号分类中获得了较好的识别效果。虽然神经网络层数的加深有利于提高网络的识别率, 但是随着网络层数的堆叠, 深层网络的收敛和优化仍然是较为棘手的问题。为了建立更高效、准确的心律不齐智能诊断模型, 本文提出将小波自适应阈值滤波和深度残差卷积神经网络 (deep residual convolutional neural network, DR-CNN) 算法用于 ECG 信号心律不齐的实时诊断。首先, 将 ECG 信号进行实时小波自适应阈值滤波, 滤除基线漂移、肌电噪声等干扰信号后进行心搏自动分割。然后, 用残差块 (residual block) 局部神经网络单元构建了适合大规模 ECG 信号训练和测试的 DR-CNN 模型, 该模型可缓解深层网络的收敛难、调优难等问题, 引入了批标准化 (batch normlization) 技术, 保证了网络稳定平滑地收敛。最后, 使用麻省理工学院和波士顿贝丝以色列医院 (Massachusetts Institute of Technology and Beth Israel Hospital, MIT-BIH) 心律不齐数据库中的 94 091 个 2 导联心搏数据进行 ECG 信号多分类、室性异位搏动 (ventricular ectopic beats, Veb) 和室上性异位搏动

(supraventricular ectopic beats, Sveb) 检测实验, 验证了本文所提算法的分类识别效果, 并给出了详细的实验结果分析。

本文提出了利用小波自适应阈值滤波与 DR-CNN 算法来进行 ECG 信号自动识别, 通过实验验证了该方法的有效性, 为 ECG 信号辅助诊断提供了新方法, 是大数据人工智能和精准辅助医疗的有效结合。最终, 期望本文方法能够应用于心脏病患者的远程实时监测和诊断, 达到提高心脏病救治率的目的。

1 心律不齐识别算法理论

1.1 小波自适应阈值去噪算法

传统的数字滤波器对 ECG 信号的滤波等预处理会引起如下问题: ① 相位移动, 比如: 巴特沃斯和切比雪夫等数字滤波在滤波前后的信号会出现时移; ② 振铃现象, 即处理后会发生一个瞬变后的震荡, 尤其是信号开始阶段, 还会引起高振幅 QRS 波终止后的低幅振荡。基于此, 本文采用具有良好的时频域局部分析能力的小波变换法进行处理, 它能同时利用信号与噪声在时、频域内的差别, 实现更为有效的信噪分离。

小波变换是时间(空间)频率的局部变换, 通过伸缩和平移可实现信号或函数的多尺度细化分析^[16-18]。具体来说, 任意函数 $f(t) \in V_0$ 都可以分解为任意尺度上的细节部分和近似部分。定义 V_0 为尺度函数 $\varphi(t)$ 的平移系列 $\varphi_k(t) = \varphi(t-k)$ 在 $L(R)$ 空间所张成的零尺度空间。设 $\Psi(t)$ 为小波函数, 则尺度函数和小波函数伸缩和平移构成的函数系分别如式(1)和式(2)所示, 它们分别构成了各个尺度空间和小波空间的规范正交基。

$$\varphi_{j,k}(t) = 2^{\frac{j}{2}} \varphi(2^j t - k) \quad (1)$$

$$\Psi_{j,k}(t) = 2^{\frac{j}{2}} \Psi(2^j t - k) \quad (2)$$

其中, $j, k \in Z$, 则离散正交小波级数如式(3)所示:

$$f(t) = \sum_{j \geq J-M}^J \sum_{k=-\infty}^{\infty} d_{j,k} \Psi_{j,k}(t) + \sum_{k=-\infty}^{\infty} c_{J-M,k} \varphi_{J-M,k}(t) \quad (3)$$

其中, J 为小波分解的最大阶数, M 为分解出的细节因子阶数, $c_{J-M,k}$ 、 $d_{j,k}$ 分别为 2^j 尺度上的尺度系数和小波系数, 可由马拉特(Mallat)快速分解算法得到, 如式(4)和式(5)所示:

$$c_{j,k} = \sum_m h(m-2k) c_{j+1,m} \quad (4)$$

$$d_{j,k} = \sum_m h(m-2k) c_{j+1,m} \quad (5)$$

由此可见, 小波分解相当于信号经过了双通道滤波器组, 该滤波器组分别具有高通和低通性质, 滤波输出对应于离散信号的低频和低频细节。在不同尺度上进行双通道滤波就实现了原始离散信号的多分辨率分解。小波滤波往往是对这些分解之后的不同尺度信号进行处理, 然后将得到的结构整合到一起恢复出原始信号。信号整合和恢复的过程称为离散小波逆变换(inverse discrete wavelet transform, IDWT), 即从低阶小波系数和尺度系数依次计算出高阶尺度系数, 最终把不同分辨率层次上展开的结果再叠加起来, 得到想要的频带信号, 甚至原始信号。Mallat 重建算法如式(6)所示:

$$c_{j+1,m} = \sum_k c_{j,k} h(m-2k) + \sum_k d_{j,k} g(m-2k) \quad (6)$$

小波自适应阈值滤波方法首先将 ECG 信号进行小波分解, 然后自适应选择阈值, 对部分细节因子去噪, 之后进行重构。阈值选择是滤波的关键, 传统信号去噪算法中阈值的选择分为硬阈值和软阈值两种方法。软阈值去噪方法可以自适应地调整不同高频带系数的阈值, 避免由于阈值过大而滤除有用信号, 或阈值过小而滤波不彻底。本文采用最高阶细节系数来估计信号高斯白噪声, 各细节因子的阈值函数定义如式(7)所示:

$$\delta_T^H(x) = \begin{cases} 0 & |x| < Th \\ \text{sign}(x)(|x| - Th) & |x| > Th \end{cases} \quad (7)$$

阈值 Th 通过如式(8)所示的公式来选择:

$$Th = \hat{\sigma} \sqrt{2 \log_e(n)} \quad (8)$$

其中, n 为噪声信号的样本点数, σ 是噪声的标准差, 可通过如式(9)所示估算得到:

$$\hat{\sigma} = \left[\frac{\text{median}(|Y_{ij}|)}{0.6745} \right] \quad (9)$$

其中, $|Y_{ij}|$ 是噪声信号小波分解的最高阶细节系数。如式(7)所示, 当细节因子高于阈值时, 取信号的模与阈值的差, 否则将细节因子置零。

1.2 DR-CNN

1.2.1 卷积神经网络 卷积神经网络(convolutional neural network, CNN)是受生物神经科学领域“感受野”概念的启示而设计的特殊的深层前馈神经网络^[19]。传统的 CNN 结构由输入层、多个交替的卷积层和池化层(下采样层)、全连接层及输出层

组成。本课题研究的是 ECG 信号的分类识别, 用来分类的数据是 2 导联的 ECG 心搏信号, 并将其作为 CNN 的输入信号。由于 CNN 的卷积层是通过卷积核重复作用于整个输入信号的每个感受野, 而卷积的结果构成输入信号的特征图。因此, 假设第 l 卷积层的第 j 通道输入 (净激活) 用 z_j^l 表示, 输出用 o_j^l 表示, 则输出 o_j^l 和输入 z_j^l 的表达式如公式 (10) 所示:

$$\begin{cases} o_j^l = f(z_j^l) \\ z_j^l = \sum_{i \in M_j} \mathbf{x}_i^{l-1} * \mathbf{k}_{ij}^l + b_j^l \end{cases} \quad (10)$$

其中, $f(\cdot)$ 为激活函数, M_j 表示 $l-1$ 层特征图子集, \mathbf{k}_{ij}^l 是卷积核矩阵, b_j^l 是偏置项, “*” 是卷积符号。

接下来, 池化层的目的是减少网络计算量, 让模型更具有鲁棒性。具体操作是将输入的特征图划分为多个不重叠的区域, 然后对各个区域求均值或者最大值, 保证了特征平移、缩放的不变性。假设采样系数用 α 表示, 符号 $\text{pool}(\cdot)$ 表示池化函数。则第 $l+1$ 层的输出特征图如式 (11) 所示:

$$\begin{cases} o_j^{l+1} = f(z_j^{l+1}) \\ z_j^{l+1} = \alpha_j^{l+1} \text{pool}(\mathbf{x}_j^l) + b_j^{l+1} \end{cases} \quad (11)$$

经过多个交替卷积和池化层, 最后是全连接层, 即将所有二维图像特征图展开为一维特征, 作为全连接网络的输入。经过上一层输出的加权求和及激活函数, 可得到全连接 m 层第 j 个神经元的输出 o_j^m , 如式 (12) 所示:

$$\begin{cases} o_j^m = f(z_j^m) \\ z_j^m = \mathbf{w}_j^m \mathbf{x}_j^{m-1} + b_j^m \end{cases} \quad (12)$$

CNN 的训练算法主要是基于梯度下降法的反向传播算法, 目标是根据训练样本和期望输出来估计网络参数, 包括卷积核参数 \mathbf{k} , 下采样网络权重 α 、全连接层网络权重 \mathbf{w} 和各层偏置 \mathbf{b} 。该算法的思想是根据样本的输出误差函数 (损失函数), 计算每层有效误差并推导出网络学习规则, 更新网络参数, 使得实际网络输出更加接近期望输出 (即损失函数最小)。由于深度学习网络一般采用批度梯度下降法来训练网络, n 个样本的整体平方误差损失函数如公式 (13) 所示:

$$J(\mathbf{k}, \alpha, \mathbf{w}, \mathbf{b}) = 1/2n \sum_{i=1}^N \|\mathbf{t}_n - \mathbf{y}_n\|^2 \quad (13)$$

利用偏导的链式法则, 逐层向前传递, 求出各层的灵敏度, 其表达式如公式 (14) 所示:

$$\delta^l = \frac{\partial J}{\partial z^l} \quad (14)$$

通过网络各层的灵敏度建立损失函数对网络参数的偏导数, 即分别计算损失函数对参数 \mathbf{k} , α , \mathbf{w} 和 \mathbf{b} 的偏导数, 并且更新各层网络参数。第 l 层卷积层参数更新方法如式 (15)、(16) 所示:

$$\mathbf{k}_{ij}^l = \mathbf{k}_{ij}^l - \eta \frac{\partial J}{\partial \mathbf{k}_{ij}^l} \quad (15)$$

$$\mathbf{b}_{ij}^l = \mathbf{b}_{ij}^l - \eta \frac{\partial J}{\partial \mathbf{b}_{ij}^l} \quad (16)$$

第 $l+1$ 层池化层参数更新方法如式 (17)、(18) 所示:

$$\alpha_{ij}^{l+1} = \alpha_{ij}^{l+1} - \eta \frac{\partial J}{\partial \alpha_{ij}^{l+1}} \quad (17)$$

$$\mathbf{b}_{ij}^{l+1} = \mathbf{b}_{ij}^{l+1} - \eta \frac{\partial J}{\partial \mathbf{b}_{ij}^{l+1}} \quad (18)$$

第 m 层全连接参数更新方法如下公式 (19)、(20) 所示:

$$\mathbf{w}_{ij}^m = \mathbf{w}_{ij}^m - \eta \frac{\partial J}{\partial \mathbf{w}_{ij}^m} \quad (19)$$

$$\mathbf{b}_{ij}^m = \mathbf{b}_{ij}^m - \eta \frac{\partial J}{\partial \mathbf{b}_{ij}^m} \quad (20)$$

其中, η 是学习率, 用于控制梯度下降行进的步长。如果学习率设置太大, 容易导致系统发散。

1.2.2 DR-CNN 深度神经网络随着层数和神经元数的增加, 非线性拟合能力会增强, 但简单的堆叠网络层数又会出现梯度消失问题, 此问题可以通过规范初始化和引入中值规范化层等方式使网络得以收敛。虽然解决了网络的收敛问题, 但是对于一个较深层的网络, 当网络模型的准确度达到饱和之后, 模型的准确率会随着深度的加深反而降低, 即出现神经网络的退化问题^[20-22], 而且此类问题并非过拟合造成的。神经网络实际上是通过调整参数来学习一种隐含的抽象映射关系, 但是这种隐含的映射关系在较深的网络中很难优化。

DR-CNN 方法则是寻求另一种解决方案, 如图 1 所示, $H(\mathbf{x})$ 是希望学习到的隐含的映射关系, DR-CNN 算法的学习过程是让多个连续堆叠的非线性计算层 (比如两层卷积) 去拟合输入数据和映射后的输出数据之间的残差 $F(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x}$, 这个残差越逼近 0, 代表这个网络提取的特征与原始的输

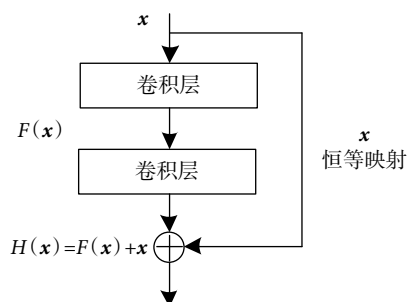


图1 残差学习:堆叠模型

Fig.1 Residual learning: a building block

入越相近。如果想拟合恒等映射,只用将权重置零;如果想拟合近似恒等映射,通过拟合残差,更容易发现小的扰动,便于调节网络参数。因此,由残差块局部深度神经网络单元构成的 CNN,能够解决深层网络的收敛难、调优难等问题,克服了 CNN 随着网络层数增加而导致的退化问题。

2 ECG 信号中心律不齐识别算法实施

2.1 数据分析及评估标准

本文实验数据来自 MIT-BIH 心律不齐数据库,该数据库共有 48 条记录,每条记录 30 min,采样率为 360 Hz。每条记录由 2 个导联组成。每条记录的导联不完全相同,只有 40 条记录包括相同的 II 导联和 VI 导联,实际应用时应考虑导联一致性,所以后续实验采用该 40 条记录的所有心搏数据。为了更加科学和便于比较,我们严格按照美国医疗器械促进协会(the Association for the Advancement of Medical Instrumentation, AAMI)标准,将 16 类心律不齐分 5 大类,分别是正常(normal, Nor)(包括正常心搏、左右束支传导阻滞等)、Sveb(包括房性早搏、交界区早搏等)、Veb(包括室性早期收缩和室性逸搏)、融合心搏(以符号 Fus 表示)和未知心搏(unclassified, Unc)(包括起搏心跳、未分类心跳等)。5 大类 2 导联心搏数量为 94 091 个。按照 AAMI 标准, Veb 和 Sveb 测试也是评估 ECG 信号采集设备性能的重要项目。为测试所设计的网络的性能,本文设计了两个实验:①是按照上述分类标准,对 94 091 个心搏进行 5 分类实验;②是测试所设计的网络对 Veb 和 Sveb 心搏的识别能力,同样按照上述分类标准并剔除了未知心搏以后,本文使用剩余 90 200 个 2 导联心搏数据。其中, Veb 测试时,将其他 3 类型心搏作为一类,即从两大类中检测 Veb 类型心搏; Sveb 测试时,将其他 3 类型心搏作为一大类,从两

大类中检测 Sveb 类型心搏。

分类模型的性能通过整体准确率(accuracy)(以符号 A_{cc} 表示)、敏感性(sensitivity)(以符号 S_e 表示)和特异性(specificity)(以符号 S_p 表示)来衡量,其中准确率是正确分类的心搏比例。每个指标具体计算方法如式(21)~(23)所示:

$$A_{cc} = \frac{TP + TN}{TP + TN + FP + FN} \quad (21)$$

$$S_e = \frac{TP}{TP + FN} \quad (22)$$

$$S_p = \frac{TN}{TN + FP} \quad (23)$$

其中,真阳性(true positive, TP)(符号记为: TP)表示本来是阳性,被正确分类的样本个数;假阳性(false positive, FP)(符号记为: FP)表示本来不是阳性,被分类为阳性的样本个数;真阴性(true negative, TN)(符号记为: TN)表示本来是阴性样本,被正确分类的样本个数;假阴性(false negative, FN)(符号记为: FN)表示本来不是阴性,被错误地分类为阴性的样本个数^[10-11]。

2.2 ECG 信号去噪

小波变换算法可以将非平稳信号分解为代表不同频带的尺度信号,广泛用于非平稳信号处理中。由于 ECG 信号采集过程中会产生基线漂移、工频干扰及高频肌电噪声,因此合理地滤波是后续识别的关键。ECG 信号中有用部分的能量主要集中在 1~40 Hz,滤波系统中采用了自适应阈值小波滤波算法,该算法包括小波分解、自适应阈值去噪和重构三步。由于 Symlet 小波函数族与 ECG 信号形态近似,故选择 Sym6 作为小波函数。由于深度学习方法可以从 ECG 信号中挖掘内部特征并自动提取,因此信号预处理阶段只用进行简单地滤波,这样有助于增强网络的泛化能力,还可以尽量减少 ECG 信号失真。因此,本文首先对 ECG 信号进行 10 层分解,利用 Mallat 算法计算细节系数和近似系数。现在已知基线漂移干扰是由人体呼吸、运动等因素引起,当受试者处于静止状态时,基线漂移通常低于 1 Hz^[23],因此在小波滤波过程中,本文将第 9 和 10 层近似系数置 0,以便去除基线漂移。而对于高频噪声,本文则采用自适应阈值算法将最高频细节成分滤波,按照均方误差准则估计信号的白噪声。

为了验证滤波效果,本文选择 MIT-BIH 数据库污染较大的 105 号 ECG 信号记录进行实验,小波滤波的效果如图 2 所示,自上向下分别为原始




图2 ECG 滤波结果比较

Fig.2 Comparison of ECG filtering results

ECG 信号、小波自适应阈值去噪信号、巴特沃斯 (Butterworth) 0.65 ~ 42 Hz 带通滤波信号和 Butterworth 1 ~ 40 Hz 带通滤波信号。

从图2中可以看出,采用 Butterworth 0.65 ~ 42 Hz 频段带通滤波后,ECG 信号出现形态失真,S 波幅度被拉长变形,而且基线移除不彻底;而经过 Butterworth 1 ~ 40 Hz 带通滤波后,P 波和 T 波明显变大,Q 波拉长变形。但本文所提出的小波阈值去噪算法,则达到了较好地去除基线和高频噪声的效果,而且较好地保持了 ECG 信号原有的形态,这样不仅有利于读图,更重要的是能提高后续 DR-CNN 算法的识别效果。

滤波之后,再进行心搏的分割,利用 ECG 信号的 R 波位置,以 R 波位置为中心,分别左边取 129 个点,右边取 220 个点,构成一个心搏信号。由于使用的数据为 2 个导联,因此每个心搏样本的大小为 2×350 。

2.3 DR-CNN 设计及实验结果分析

由于网络层数和复杂度会大大影响训练结果,本文设计了不同层数和结构的 DR-CNN 模型,进

行了反复实验和对比。如图3所示,是对 8、12、16、20 和 24 层的 DR-CNN 网络的每次 (epoch) 训练所得的交叉验证准确率的统计结果。

如图3所示,20 层的 DR-CNN 达到了较好的训练和测试结果,24 层的网络性能与 20 层相当,考虑到系统测试的实时性要求,因此本文选择了 20 层网络作为系统的诊断模型。

本系统所采用的 20 层 DR-CNN 的模型结构如图4所示。输入数据为 2 导联的心搏数据,大小为 2×350 ,经过核大小为 2×3 的一层卷积层和 9 个残差块,最后通过均值下采样,将数据送入神经元个数与分类数相等的全连接层,该网络模型共 20 个参数层。其中,每个短路连接构成一个残差块,实线代表通道数(维度)相同,虚线代表通道数有变化。当恒等映射时维度不同,可通过两种方法来解决:一是可以通过 pad 补零操作增加维数;二是使用核为 1×1 卷积层来扩充维度,使输出维度与下一个残差模块一致。

为了评估所提出的基于 DR-CNN 的 ECG 信号中心律不齐的识别效果,本实验基于 MIT-BIH 心




图3 ECG分类训练及测试结果对比

Fig.3 Comparison of training and testing results of ECG classification

律不齐数据库,对所有40条导联一致的样本进行滤波去噪,根据R波位置分割出94 091个心搏信号。在所有心搏样本中随机抽取60 000个心搏进行训练,剩余34 091个心搏作为预测数据,进行5大类心律不齐信号的分类。为了避免随机抽取的偶然性,使用随机排序函数进行了3次随机抽取实验,实验结果取3次实验的平均值。然后,设计了相同复杂度的CNN和多层感知机(multi-layer perceptron, MLP),并且将结构参数调整至最优,使用相同的数据对三个网络分别进行了30次(epoch)训练,并对测试结果进行对比。实验所得的混合矩阵及评估指标如表1所示。

为了避免测试结果的偶然性,进行了3次实验,结果取3次实验的平均值。每次实验过程中,将94 091个心搏数据随机划分为训练数据和测试数据两部分,两者没有重复样本。从表1的实验结果可看出,本文设计的算法对5大类心律不齐分类准确率达到99.034 9%。通过实验对比,所设计的DR-CNN算法对5大类心律不齐信号的识别准确率比CNN和MLP网络分别提高了0.753 8%和2.360 4%。DR-CNN测试的敏感性 S_e 平均值为94.532%,CNN和MLP测试的平均值分别为87.706%和75.8%,由此可见,敏感性得到提升。

本文对所提出的系统进行了Veb和Sveb测试,每次随机选择40 000个心搏对网络进行训练,剩余50 200个心搏进行测试,3次测试结果的平均值作为计算指标的依据,统计结果如表2所示。DR-CNN网络的Veb和Sveb测试准确率分别达到了99.498 0%和99.599 6%。Veb测试结果显示,DR-CNN、CNN和MLP网络的敏感性测试结果分别为95.79%、67.38%和86.07%,即DR-CNN的测试结果95.79%比CNN和MLP的测试结果67.38%和86.07%分别提高了28.41%和9.72%;Sveb测试结果显示,DR-CNN、CNN和MLP网络的敏感性测试结果分别为93.42%、54.16%和56.78%,即DR-CNN的测试结果93.42%比CNN和MLP的测试结果54.16%和56.78%分别提高了39.26%和36.64%。

本文通过对比研究了近期用深度学习方法进行ECG信号分类的研究成果。在相同的数据集下的测试结果如表3所示。金林鹏等^[11]采用导联卷积深度神经网络,分别用MIT-BIH心律不齐数据库数据和临床大数据进行了ECG信号自动识别。该文献利用MIT-BIH心律不齐数据库对86 010个心搏进行正异常二分类,分类整体准确率达到98.89%。Kiranyaz等^[13]采用一维CNN对心律不齐

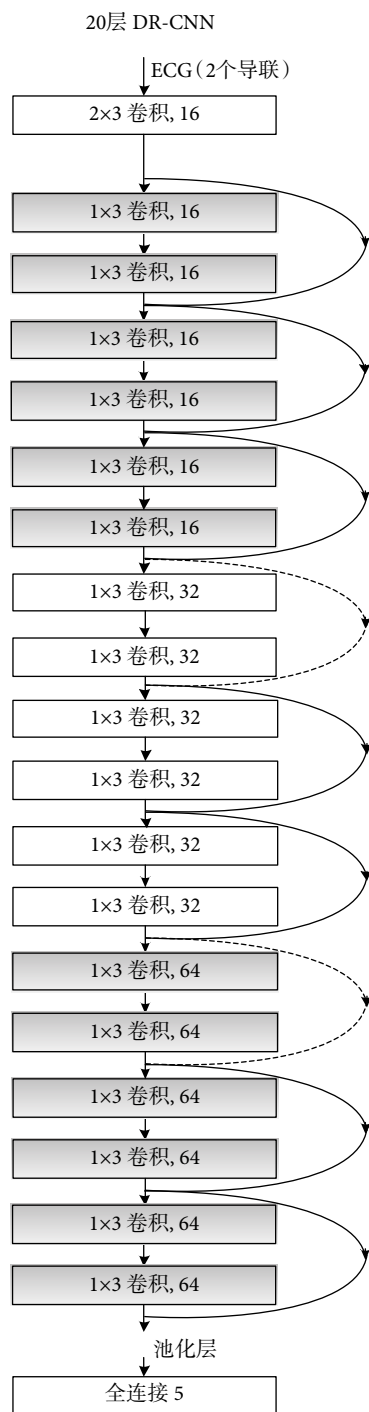


图4 DR-CNN 识别模型结构

Fig.4 Recognition model of DR-CNN

进行5分类,并且进行Veb和Sveb检测。使用44条ECG信号记录时,5类心律不齐分类准确率为98.84%,Veb和Sveb检测准确率分别为99%和97.6%。Wu等^[14]提出利用深度置信网络进行ECG信号心律不齐分类,按照AAMI标准,进行了心律不齐(Nor、Sveb、Veb、Fus)4分类,分类准确率为96.51%;Veb和Sveb测试准确率分别为97.9%和99.3%。一般情况下分类种类越多,识别准确率越

低。从表3中可以看出,所提出的小波滤波和DR-CNN的ECG信号识别实验取得了较高的准确率,有一定的临床应用价值。

3 结论

ECG信号去噪和自动分类算法是心律不齐自动诊断的核心技术,本文提出了一种基于小波自适应阈值滤波和DR-CNN的ECG信号心律不齐智能识别算法。所提出的小波自适应阈值去噪算法,有效地移除了基线漂移等干扰,并且保持了ECG信号形态不失真。设计了基于20层的DR-CNN模型,该模型克服了深度神经网络近似恒等映射时随着网络层数增加而导致的退化问题,并保证了网络的平滑收敛性。基于DR-CNN,分别利用MIT-BIH数据库94 091和90 200个心搏数据进行了ECG心律不齐信号多分类、Veb和Sveb识别的实验验证。在相同实验环境下,对比了目前较流行的几种深度神经网络算法,实验结果表明所提出的方法有效地提高了ECG心律不齐信号的整体识别准确率、敏感性和特异性。该方法将人工智能与ECG信号分类识别相结合,可用于新型的心脏病辅助诊断系统,通过可穿戴终端采集ECG信号,远程实时发送到ECG云计算平台,经过数据变换、小波自适应去噪、QRS复波识别、分割等预处理,基于DR-CNN算法对心律不齐病症进行实时诊断,并返回客户端。这种基于深度学习的心律不齐自动诊断方法可以与可穿戴设备、物联网和无线通信技术相结合,进一步推动新型智慧医疗的发展,将心脏病的预防、监测和诊断延伸到家庭、养老院等院外场景,为医学薄弱的地区补上短板,为患者提供高效的服务,可大大节约医疗资源。

参考文献

- 1 Huikuri H V, Castellanos A, Myerburg R J. Sudden death due to cardiac arrhythmias. *N Engl J Med*, 2001, 345(12): 1473-1482.
- 2 Homaeinezhad M R, Atyabi S A, Tavakkoli E, et al. ECG arrhythmia recognition via a neuro-SVM-KNN hybrid classifier with virtual QRS image-based geometrical features. *Expert Syst Appl*, 2012, 39(2): 2047-2058.
- 3 Guo Shuli, Han Lina, Liu Hongwei, et al. The future of remote ECG monitoring systems. *J Geriatr Cardiol*, 2016, 13(6): 528-530.
- 4 Yin Wenfeng, Yang Xiuzhu, Zhang Lin, et al. ECG monitoring system integrated with IR-UWB radar based on CNN. *IEEE Access*, 2016, 4: 6344-6351.
- 5 Clifford G, Tarassenko L, Townsend N. One-pass training of optimal architecture auto-associative neural network for detecting ectopic beats. *Electron Lett*, 2001, 37: 1126-1127.
- 6 Moein S. An MLP neural network for ECG noise removal based on

表 1 AAMI 标准下 MIT-BIH 数据心律不齐分类结果对比

Tab.1 Comparison of arrhythmia classification results based on MIT-BIH database according to AAMI

方法		混合矩阵					评估指标		
		Nor	Sveb	Veb	Fus	Unc	S_e	S_p	A_{cc}
DR-CNN	Nor	28 820	46	44	19	2	99.62%	96.40%	99.034 9%
	Sveb	106	889	1	0	0	89.26%	99.85%	
	Veb	56	2	2 459	7	0	97.42%	99.79%	
	Fus	18	0	19	248	0	87.02%	99.92%	
	Unc	6	0	3	0	1 346	99.34%	99.99%	
CNN	Nor	28 861	30	34	1	5	99.76%	90.76%	98.281 1%
	Sveb	198	796	2	0	0	79.92%	99.89%	
	Veb	193	7	2 308	13	3	91.44%	99.84%	
	Fus	77	1	13	194	0	68.07%	99.96%	
	Unc	9	0	0	0	1 346	99.34%	99.98%	
MLP	Nor	28 659	121	135	9	7	99.06%	84.92%	96.674 5%
	Sveb	467	528	1	0	0	53.01%	99.60%	
	Veb	149	12	2 352	4	7	93.19%	99.38%	
	Fus	131	0	49	105	0	36.84%	99.96%	
	Unc	31	0	11	0	1 313	96.90%	99.96%	

表 2 Veb 及 Sveb 测试结果对比

Tab.2 Comparison of test results of Veb and Sveb

方法		Veb					Sveb				
		Nor	Veb	S_e	S_p	A_{cc}	Nor	Sveb	S_e	S_p	A_{cc}
DR-CNN	Nor	46 145	85	99.82%	95.79%	99.498%	Nor	48 607	103	99.79%	93.42%
	Veb	167	3 803	95.79%	99.82%		Sveb	98	1 392	93.42%	99.79%
CNN	Nor	45 451	779	98.31%	67.38%	95.868 5%	Nor	48 002	708	98.55%	54.16%
	Veb	1 295	2 675	67.38%	98.31%		Sveb	683	807	54.16%	98.55%
MLP	Nor	45 819	411	99.11%	86.07%	98.079 7%	Nor	48 448	262	99.46%	56.78%
	Veb	553	3 417	86.07%	99.11%		Sveb	644	846	56.78%	99.46%

表 3 与其它文献所提方法的识别效果进行比较

Tab.3 Comparison of the experimental results with the results from the literatures

方法	类别数	多分类		Sveb		Veb	
		A_{cc}	S_e	A_{cc}	S_e	A_{cc}	S_e
金林鹏等 ^[11]	2	98.89%	*	*	*	*	*
Kiranya 等 ^[13]	5	98.84%	60.3%	97.6%	93.9%	99%	
Wu 等 ^[14]	4	96.51%	90.2%	99.3%	85.8%	97.9%	
本文算法	5	99.034 9%	93.42%	99.599 6%	95.79%	99.498%	

Kalman filter. *Adv Exp Med Biol*, 2010, 680: 109-116.

- Inan O T, Giovangrandi L, Kovacs G T. Robust neural-network-based classification of premature ventricular contractions using wavelet transform and timing interval features. *IEEE Trans Biomed Eng*, 2006, 53(12): 2507-2515.
- Yu S N, Chen Y H. Electrocardiogram beat classification based on wavelet transformation and probabilistic neural network. *Pattern Recognit Lett*, 2007, 28(10): 1142-1150.
- Ebrahimzadeh A, Khazaee A. Detection of premature ventricular contractions using MLP neural networks: a comparative study. *Measurement*, 2010, 43(1): 103-112.
- Li Duan, Zhang Hongxin, Zhang Mingming. Wavelet de-noising and genetic algorithm-based least squares twin SVM for classification of arrhythmias. *Circuits Systems and Signal Processing*, 2017, 36(7): 2828-2846.
- 金林鹏, 董军. 面向临床心电图分析的深度学习算法. 中国科学:信息科学, 2015, 45(3): 398-416.
- Rajpurkar P, Hannun A Y, Haghpanahi M, et al. Cardiologist-level arrhythmia detection with convolutional neural networks. Cornell University arXiv. (2017-07-06). <http://arxiv.org/abs/1707.01836v1>.
- Kiranyaz S, Ince T, Gabbouj M. Real-time patient-specific ECG classification by 1-D convolutional neural networks. *IEEE Trans Biomed Eng*, 2016, 63(3): 664-675.
- Wu Z Y, Ding X Q, Zhang G R. A novel method for classification of ECG arrhythmias using deep belief networks. *International Journal of Computational Intelligence and Applications*, 2016, 15(4): 1650021.
- 陈诗慧, 刘维湘, 秦璟, 等. 基于深度学习和医学图像的癌症计算机辅助诊断研究进展. 生物医学工程学杂志, 2017, 34(2): 314-319.
- 张贤达. 现代信号处理. 译. 第2版. 北京: 清华大学出版社, 2002.
- Milchevski A, Gusev M. Improved pipelined wavelet



- implementation for filtering ECG signals. [Pattern Recognit Lett, 2017](#), 95: 85-90.
- 18 Sahoo S, Kanungo B, Behera S, *et al.* Multiresolution wavelet transform based feature extraction and ECG classification to detect cardiac abnormalities. [Measurement, 2017](#), 108: 55-66.
- 19 王媛媛, 周涛, 陆惠玲, 等. 基于集成卷积神经网络的肺部肿瘤计算机辅助诊断模型. *生物医学工程学杂志*, 2017, 34(4): 543-551.
- 20 He Kaiming, Zhang Xiangyu, Ren Shaoqing, *et al.* Deep residual learning for image recognition//2016 IEEE Conference on Computer Vision and Pattern Recognition (CPVR). Las Vegas, USA, 2016: 770-778.
- 21 Yu Lequan, Chen Hao, Dou Qi, *et al.* Automated melanoma recognition in dermoscopy images via very deep residual networks. [IEEE Trans Med Imaging, 2017](#), 36(4): 994-1004.
- 22 Zagoruyko S, Komodakis N. Wide residual networks. (2017-07-14). <http://arxiv.org/abs/1605.07146>.
- 23 Bahoura M, Hassani M, Hubin M. DSP implementation of wavelet transform for real time ECG wave forms detection and heart rate analysis. [Comput Meth Prog Bio, 1997](#), 52(1): 35-44.

收稿日期: 2017-12-13 修回日期: 2019-01-09

本文编辑: 陈咏竹

(上接第188页; *Continued from Page 188*)

- 22 Ferlazzo E, Mammone N, Cianci V, *et al.* Permutation entropy of scalp EEG: a tool to investigate epilepsies: suggestions from absence epilepsies. [Clin Neurophysiol, 2014](#), 125(1): 13.
- 23 Li Xiaoli, Cui Suyuan, Voss L J. Using permutation entropy to measure the electroencephalographic effects of sevoflurane. [Anesthesiology, 2008](#), 109(3): 448-456.
- 24 Rosso O A, Blanco S, Yordanova J, *et al.* Wavelet entropy: a new tool for analysis of short duration brain electrical signals. [J Neurosci Methods, 2001](#), 105(1): 65-75.
- 25 Kim H J, Fay M P, Feuer E J, *et al.* Permutation tests for joinpoint regression with applications to cancer rates. [Stat Med, 2000](#), 19(3): 335-351.
- 26 Mueller A, Candrian G, Kropotov J D, *et al.* Classification of ADHD patients on the basis of independent ERP components using a machine learning system. [Nonlinear Biomed Phys, 2010](#), 4(Suppl 1): 1-12.
- 27 Tenev A, Markovska-Simoska S, Kocarev L A, *et al.* Machine learning approach for classification of ADHD adults. [Int J Psychophysiol, 2014](#), 93(1): 162-166.
- 28 奉国和. SVM分类核函数及参数选择比较. [计算机工程与应用, 2011](#), 47(3): 123-124, 128.
- 29 林升梁, 刘志. 基于RBF核函数的支持向量机参数选择. [浙江工业大学学报, 2007](#), 35(2): 163-167.
- 30 李盼池, 许少华. 支持向量机在模式识别中的核函数特性分析. [计算机工程与设计, 2005](#), 26(2): 302-304.

收稿日期: 2017-09-21 修回日期: 2019-03-06

本文编辑: 李蓓兰